

Clasificacion de razas con Oxford IIIT Pet

Actividad grupal de Redes Neuronales Convolucionales

Informe tecnico de la comparacion experimental entre un modelo Fully Connected, tres CNN propias y dos etapas de transferencia con MobileNetV2. La seleccion se realizo exclusivamente con validacion y el conjunto de test se abrio al final.

86.14%	85.10%	88.04%
Accuracy final en test	Macro F1 en test	Accuracy de validacion

Resultado principal. *mobilenet_finetuned* alcanzo 86.14% de accuracy y 85.10% de macro F1. Supero el objetivo de 85% con una brecha train-validation de 2.99% en la mejor epoca, sin evidencia fuerte de overfitting o underfitting.

Entorno	Configuracion verificada
Equipo	Apple M5, 16 GB de memoria
Aceleracion	TensorFlow Metal - GPU detectada
Software	Python 3.12.14, TensorFlow 2.18.1, TFDS 4.9.10
Datos	2,944 train / 368 validation / 368 test; 37 razas
Fecha de ejecucion	11 de septiembre de 2026

Sistemas Cognitivos Artificiales

1 Objetivo y metodologia

El objetivo fue entrenar un clasificador de las 37 razas de perros y gatos del Oxford-IIIT Pet Dataset, lograr al menos 85% de accuracy en test y demostrar que el modelo seleccionado no presenta senales relevantes de sobreajuste o subajuste.

Protocolo experimental

La plantilla original contenia `train[:80]`, expresion que selecciona 80 observaciones. Se corrigio a un corte porcentual 80/10/10. Las imagenes se redimensionaron a 160 x 160, se normalizaron a [0, 1] y se procesaron con `tf.data`. Se fijaron semillas, se guardo el mejor checkpoint por accuracy de validacion y se aplico parada temprana.

Etapas	Uso autorizado	Control metodologico
Train	Ajuste de pesos	Shuffle, batches, augmentation segun experimento
Validation	Seleccion y callbacks	Mejor checkpoint por val_accuracy
Test	Evaluacion final	No se uso para elegir modelo ni hiperparametros

Criterios de evaluacion

Se compararon accuracy, precision, recall, macro F1 y weighted F1. Las curvas de train y validation se analizaron en la epoca del mejor checkpoint. Una brecha mayor a 10 puntos se trato como posible overfitting y una accuracy de validacion menor de 50% como posible underfitting. Este diagnostico automatico se complemento con la matriz de confusion y la revision visual de errores.

2 Analisis exploratorio

El split completo contiene 3,680 imagenes del conjunto train suministrado por TFDS. Cada particion conserva las 37 etiquetas, aunque el numero de ejemplos por clase en validation y test es reducido. El problema incluye variaciones de escala, pose, iluminacion, fondo y encuadre, ademas de razas con morfologia muy similar.




Figura 1. Muestra reproducible de imagenes del conjunto de entrenamiento.

3 Diseno experimental

Se ejecutaron seis experimentos. Las dos variantes de la CNN regularizada comparten arquitectura, optimizador e hiperparametros; la unica diferencia controlada es el aumento de datos. MobileNetV2 utiliza pesos de ImageNet y una normalizacion interna de [0, 1] a [-1, 1].

Modelo	Arquitectura	Aug.	Regularizacion	Funcion experimental
fc_baseline	Resize 64, Flatten, Dense	No	Dropout	Baseline sin estructura espacial
cnn_baseline	3 bloques Conv2D	No	Ninguna avanzada	Aporte basico convolucional
cnn_regularized_no_aug	4 bloques CNN propios	No	BN + spatial dropout	Control de la ablacion
cnn_regularized_aug	Misma CNN propia	Si	BN + spatial dropout	Efecto aislado de augmentation
mobilenet_transfer	MobileNetV2 congelada	Si	Dropout	Transfer learning
mobilenet_finetuned	Ultimas 30 capas habilitadas	Si	BN congelada + LR bajo	Adaptacion final al dominio

Trazabilidad y reproducibilidad

Cada experimento produjo un modelo Keras completo, historial JSON y registro CSV por epoca. Los checkpoints existentes se cargan sin reentrenar cuando FORCE_RETRAIN=False. La ejecucion final genero seis modelos y 27 artefactos; el entorno Metal se verifico antes del entrenamiento.

4 Resultados comparativos

Modelo	Val. acc.	Test acc.	Macro F1	Diagnostico
mobilenet_finetuned	88.0%	86.1%	85.1%	sin evidencia fuerte en las curvas
mobilenet_transfer	87.8%	84.2%	83.4%	sin evidencia fuerte en las curvas
cnn_regularized_no_aug	24.5%	25.0%	21.4%	posible underfitting
cnn_regularized_aug	17.4%	15.8%	13.4%	posible underfitting
cnn_baseline	11.1%	9.8%	6.1%	posible underfitting
fc_baseline	7.3%	3.5%	0.7%	posible underfitting




Figura 2. Accuracy final de los seis modelos; la linea roja marca el objetivo.

La transferencia produjo el cambio decisivo: MobileNetV2 congelada obtuvo 84.24% y el fine tuning parcial elevo el resultado a 86.14%, una mejora de 1.90 puntos. Las arquitecturas entrenadas desde cero permanecieron subajustadas bajo el presupuesto experimental, por lo que no compitieron con las representaciones preentrenadas.

5 Selecccion y generalizacion

El modelo se selecciono antes de abrir test. *mobilenet_finetuned* obtuvo 88.04% en validation y fue el mejor checkpoint. En su mejor epoca registro 91.03% en train y 88.04% en validation, una brecha de 2.99 puntos. La parada temprana restaura ese checkpoint aunque el entrenamiento continuara hasta completar la paciencia configurada.




Figura 3. Curvas del modelo seleccionado; el mejor checkpoint corresponde a la epoca 2.

Lectura de las curvas

La accuracy de train aumento despues de la mejor epoca, mientras validation se mantuvo entre aproximadamente 86.96% y 88.04%. La loss de validation no mostro una mejora sostenida posterior. Esta separacion moderada justifica conservar el checkpoint temprano; no alcanza el umbral de 10 puntos establecido para una alerta fuerte de overfitting.

Metricas finales del modelo seleccionado

Accuracy	Precision macro	Recall macro	F1 macro	F1 ponderado
86.14%	86.43%	85.81%	85.10%	86.01%

La proximidad entre macro F1 (85.10%) y weighted F1 (86.01%) indica que el resultado global no depende exclusivamente de las clases con mas ejemplos. Sin embargo, el soporte por raza en test es pequeno; por ello las diferencias por clase deben interpretarse como evidencia descriptiva de esta particion, no como estimaciones definitivas.

6 Resultados por clase

Las 37 clases se ordenan de menor a mayor F1 para hacer visibles las debilidades. Beagle fue la clase mas difícil (62.50% F1). Ragdoll y Bengal obtuvieron 66.67%; Birman alcanzo 71.43%. Varias razas lograron F1 perfecto en esta particion, pero con soportes de entre 5 y 16 imagenes.

Raza	Precision	Recall	F1	Soporte
beagle	71.4%	55.6%	62.5%	9
Ragdoll	55.6%	83.3%	66.7%	6
Bengal	71.4%	62.5%	66.7%	8
Birman	83.3%	62.5%	71.4%	16
Persian	100.0%	57.1%	72.7%	7
chihuahua	100.0%	60.0%	75.0%	10
american_pit_bull_terrier	75.0%	75.0%	75.0%	8
Maine_Coon	62.5%	100.0%	76.9%	5
Abyssinian	68.8%	91.7%	78.6%	12
Russian_Blue	71.4%	90.9%	80.0%	11
english_setter	75.0%	85.7%	80.0%	7
Siamese	83.3%	76.9%	80.0%	13
leonberger	66.7%	100.0%	80.0%	4
staffordshire_bull_terrier	75.0%	90.0%	81.8%	10
pomeranian	100.0%	71.4%	83.3%	7
miniature_pinscher	83.3%	83.3%	83.3%	6
Egyptian_Mau	100.0%	72.7%	84.2%	11
boxer	88.9%	80.0%	84.2%	10
samoyed	90.9%	83.3%	87.0%	12

Tabla 1. Metricas por clase, primera mitad, ordenadas por F1 ascendente.

6 Resultados por clase continuacion

Raza	Precision	Recall	F1	Soporte
german_shorthaired	87.5%	87.5%	87.5%	8
great_pyrenees	85.7%	92.3%	88.9%	13
Bombay	100.0%	81.8%	90.0%	11
keeshond	100.0%	83.3%	90.9%	6
english_cocker_spaniel	83.3%	100.0%	90.9%	10
newfoundland	83.3%	100.0%	90.9%	5
havanese	91.7%	91.7%	91.7%	12
British_Shorthair	91.7%	91.7%	91.7%	12
american_bulldog	91.7%	91.7%	91.7%	12
saint_bernard	92.3%	92.3%	92.3%	13
japanese_chin	87.5%	100.0%	93.3%	14
Sphynx	88.2%	100.0%	93.8%	15
shiba_inu	100.0%	88.9%	94.1%	9
scottish_terrier	100.0%	91.7%	95.7%	12
basset_hound	92.3%	100.0%	96.0%	12
wheaten_terrier	100.0%	100.0%	100.0%	8
pug	100.0%	100.0%	100.0%	14
yorkshire_terrier	100.0%	100.0%	100.0%	10

Tabla 1. Metricas por clase, segunda mitad.

Interpretacion

Los errores se concentran en razas visualmente proximas. Las metricas mas bajas no sugieren una sola falla sistematica: aparecen gatos de pelo largo, gatos con patrones similares y perros con siluetas compartidas. El pequeno soporte hace que dos o tres errores modifiquen de forma importante el recall de una clase.

7 Matriz de confusion

La diagonal dominante confirma el buen rendimiento general. Los pares fuera de la diagonal muestran errores localizados, principalmente entre razas que comparten color, longitud de pelaje, forma facial o tamaño corporal.




Figura 4. Matriz de confusion normalizada del modelo MobileNetV2 con fine tuning.

7 Pares de confusion principales

Raza real	Prediccion	Errores	Tasa dentro de la clase
Persian	Maine_Coon	3	42.9%
Bengal	Abyssinian	3	37.5%
Birman	Ragdoll	3	18.8%
chihuahua	staffordshire_bull_terrier	2	20.0%
Egyptian_Mau	Bengal	2	18.2%
samoyed	great_pyrenees	2	16.7%
Birman	Siamese	2	12.5%
keeshond	leonberger	1	16.7%
miniature_pinscher	Sphynx	1	16.7%
Ragdoll	Birman	1	16.7%

Persian se confundio con Maine Coon en 3 de 7 casos; Bengal con Abyssinian en 3 de 8; y Birman con Ragdoll en 3 de 16. Estos pares son coherentes con similitudes morfológicas. Samoyed y Great Pyrenees comparten pelaje blanco abundante, mientras Birman, Ragdoll y Siamese comparten patrones de color point.

8 Analisis visual de errores

La galeria prioriza errores de alta confianza. Los casos mas seguros incluyen Persian predicho como Maine Coon, Samoyed como Great Pyrenees y Birman como Ragdoll. Tambien aparecen sujetos pequenos, fondos dominantes, iluminacion atipica y encuadres donde la morfologia completa no es visible.




Figura 5. Dieciseis errores con mayor confianza del modelo seleccionado.

9 Impacto de data augmentation

La ablacion controlada no mostro una mejora. La CNN regularizada sin augmentation alcanzo 25.00% en test, mientras la variante con augmentation obtuvo 15.76%. La diferencia fue -9.24 puntos porcentuales.

Variante	Val. accuracy	Test accuracy	Macro F1	Diagnostico
Sin augmentation	24.5%	25.0%	21.4%	posible underfitting
Con augmentation	17.4%	15.8%	13.4%	posible underfitting

Como ambas variantes permanecieron en underfitting, el resultado no implica que el augmentation sea perjudicial en general. En este presupuesto de entrenamiento, las transformaciones aumentaron la dificultad de optimizacion y la red propia no aprendio representaciones suficientemente discriminativas. Una nueva iteracion deberia ajustarse solo con train y validation, sin reabrir test.

10 Conclusiones

El objetivo academico se cumplio. MobileNetV2 con fine tuning parcial fue seleccionada por validation y obtuvo 86.14% de accuracy, 86.43% de precision macro, 85.81% de recall macro y 85.10% de macro F1 en test. La brecha train-validation del mejor checkpoint fue 2.99 puntos, por debajo del criterio de alerta definido.

La comparacion demuestra que las representaciones preentrenadas fueron esenciales para este conjunto y presupuesto. El Fully Connected obtuvo 3.53%; la mejor CNN entrenada desde cero, 25.00%; MobileNetV2 congelada, 84.24%; y el fine tuning agrego 1.90 puntos hasta superar el umbral. El analisis por clase identifica oportunidades en razas visualmente cercanas, sin utilizar esa evidencia para modificar el modelo despues de abrir test.

Limitaciones

El test contiene 368 imagenes, con pocos ejemplos por raza. Una sola particion no cuantifica la variabilidad entre semillas. Ademas, los umbrales automaticos de overfitting y underfitting son criterios operativos, no pruebas estadisticas. Los resultados son reproducibles mediante los checkpoints, historiales y configuracion guardados.

Referencias

1. Parkhi, O. M. et al. *Cats and Dogs*. IEEE CVPR, 2012. [Oxford-IIIT Pet Dataset](#).
2. TensorFlow Datasets. [Oxford IIIT Pet catalog](#).
3. TensorFlow. [Transfer learning and fine tuning](#).
4. Sandler, M. et al. *MobileNetV2: Inverted Residuals and Linear Bottlenecks*. CVPR, 2018.